

Introduction To Deep Learning Course

Undergraduate elective course

Spring semester



Lecturer: Matan Cohen

Email: matanyc1@gmail.com

Course details:

Deep learning is one of the biggest revolutions of our days. Deep learning has brought us incredible breakthroughs that enable driverless cars, face recognition, the greatly improved Google Translate and fluent conversations with digital personal assistants. The field is at the forefront of research and industry and the demand for more researchers has only grown.

In this course we will learn the fundamental mathematical in this field and we will understand the concepts that lead this revolution. We will dive deeper into the main three pillars – Expressiveness, Optimization, and Generalization, and study the recent research which will shed some light on the learning process itself. In addition, we will learn about the neural network architectures from various domains, such as Image processing and Natural Language Processing, we will build and train networks in python and solve real-industry complex tasks. Moreover, we will learn about the recent trends in the field and some of its open problems.

Requirements:

Introduction to Computer Science, Probability, calculus, linear algebra, programming basic concepts (functions, classes, loops,...) in Python/C#/Java.

Course structure:

Part 1 – basic mathematical recap and fundamental Deep Learning concepts

- Recap on a chosen subject in calculus, Linear Algebra and Probability.
- Introduction to Machine Learning – Overview, The Learning framework through "toy example", linear regression and feature mapping.
- Fully connected neural networks, loss functions and Gradient descent algorithm.
- Optimization - convex problems and Deep learning as a non-convex problem.
- Generalization – the empirical phenomena, generalization and regularization.

Part 2 – Deep Convolutional Networks and Training

- Deep Convolutional Networks – we will study the Neural network structure, its different layer types (like Convolutional Layer, Pooling Layer and Batch normalization) and their purpose in the learning process.
- Training Neural networks – the right learning process, well known related problems (such as vanishing/exploding gradients) and the theoretical and practical concepts in this procedure (weight initialization, batch normalization, regularization).
- Python practice and relevant packages Pytorch, Sklearn and Pandas.

Part 3 – Neural network in NLP, RNNs and Transformers

- Word Embedding – word2vec (skipgram and cbow) and glove.
- The architecture of Vanilla RNN, LSTM and GRU.
- Attention and Transformers – we will learn about attention layer for NLP tasks and about Transformers.

Part 4 – advanced topics

- Generative models.
- Uncertainty, calibration and additional subjects.

Grade Composition:

65% home assignments and project.

35% test.

תקציר הקורס:

למידה עמוקה היא אחת המהפכות הגדולות ביותר בעידן שלנו. תחום זה הקדים את תחזיות המחקר ואפשר פריצות דרך שנראו דמיוניות רק לפני שנים אחדות כמו נהיגה אוטונומית, זיהוי אנשים, תרגום מתקדם בזמן אמת ושיחות שוטפות עם עוזרים דיגיטליים. התחום נמצא בחזית המחקר והתעשייה והדרישה לחוקרים נוספים רק גדלה.

בקורס זה נלמד את העקרונות המתמטיים שעומדים בבסיס תחום זה ונבין את הרעיונות המרכזיים שאפשרו את המהפכה הנוכחית. בקורס נסקור בשלושת העקרונות התיאורטיים המרכזיים - אקספרסיביות, אופטימיזציה והכללה, ואת המחקר העדכני בהם, שישפוך מעט אור על תהליך הלמידה עצמו.

כמו כן, נלמד על ארכיטקטורות של רשתות נפוצות ממספר תחומים, כמו עיבוד תמונה ועיבוד שפה טבעית, נבנה ונאמן רשתות שנפתח בpython ונפתור משימות מורכבות שמגיעות מהתעשייה. בנוסף נלמד על כיווני המחקר העדכניים בתחום ועל הבעיות הפתוחות בו.

דרישות קדם:

סיום בהצלחה של הקורסים מבוא למדעי המחשב, חשבון דיפרנציאלי ואינטגרלי, אלגברה ליניארית והסתברות, היכרות עם קונספטים בסיסיים של תכנות (פונקציות, מחלקות, לולאות...) באחת השפות python/c#/java.

מבנה הקורס:

חלק ראשון – חיזוק היסודות המתמטיים הדרושים לתחום וחשיפה לעקרונות הבסיסיים בו

- חזרה על הידע הדרוש בחדו"א אלגברה ליניארית והסתברות.

- מבוא ללמידת מכונה – סקירה של התחום, הסבר תהליך הלמידה הכללי דרך "דוגמת צמצום", linear regression ו feature mapping.
- רשתות fully connected, פונקציות loss ואלגוריתם Backpropagation.
- אופטימיזציה בלמידה עמוקה - בעיות קונבקסיות ולמידה עמוקה כבעיה לא קונבקסית.
- הכללה בלמידה עמוקה – התופעות האימפריות של רשתות, חסמי הכללה ו implicit regularization.

חלק שני –רשתות קונבולוציה עמוקות ואימון נכון של רשתות

- רשתות קונבולוציה – לימוד מבנה הרשת, השכבות השונות בה (קונבולוציה, pooling, batch normalization) וייעודן בהליך הלמידה.
- אימון רשתות – כיצד לאמן נכון רשתות, בעיות ידועות בתהליך (לדוגמה vanishing/exploding gradient), ועקרונות תיאורטיים ופרקטיים למשימה זו (weight regularization, batch normalization, initialization).
- תרגול python ושימוש בחבילות רלוונטיות pytorch, sklearn, pandas.

חלק שלישי רשתות בתחום הNLP, RNN וTransformers

- Word embedding - נלמד על אלגוריתמי word2vec (skipgram and cbow) ו glove.
- מבנה הרשתות של Vanilla RNN, LSTM and GRU.
- Attention and Transformers –נלמד על גישות שמשלבות attention למשימות NLP ובפרט על טרנספורמרים.

חלק רביעי – נושאים מתקדמים

- מודלים ג'נרטיביים ורשתות כמייצרי דאטה.
- חוסר וודאות ברשתות, קליברציה ונושאים נוספים.

הרכב הציון:

- 65% תרגילי בית ועבודה בזוגות.
- 35% מבחן.